MERRA-2 气溶胶数据获取与近地面 PM_{10} 估算

阶段性研究工作报告

研究区域：中国四省区及周边七国

本阶段重点时段：2015 年至最新实际可用日期

日期：2026 年 10 月 21 日

版本：V2.0｜组会审阅稿

报告范围：数据来源与选择依据、区域子集获取、近地面 PM_{10} 计算、时空匹配及观测比较方案。数据下载和流程验证为当前工作重点，观测精度评价尚待开展。

摘要

为构建研究区域近地面 PM_{10} 的连续时空数据，本阶段采用 NASA 发布的 MERRA-2 三维气溶胶再分析产品 M2I3NVAER 5.12.4，选取最接近地面的第 72 模式层，获取空气密度及硫酸盐、黑碳、有机碳、沙尘和海盐相关变量。依据当前采用的文献组分方案，在原始网格上逐时次估算 PM_{10}，保留 3 小时时间分辨率，并按区域、按年份保存为 NetCDF4。

国内范围为宁夏、新疆、甘肃和内蒙古，国外扩展范围为蒙古国、哈萨克斯坦、吉尔吉斯斯坦、塔吉克斯坦、阿富汗、巴基斯坦和印度。本阶段重点获取 2015 年至最新实际可用日期的数据，保留原始日文件和任务记录，为后续点位提取、方法复核及观测比较提供可追溯的数据基础。

现有运行记录表明，蒙古国 2024 年已完成 366 个日文件、2928 个时次的 PM_{10} 计算和年度写出，验证了完整年度处理流程。多区域、多年份任务仍在推进，实际完成范围需逐年盘点。城市代表点的来源、地面观测资料和时空配对规则仍需核实，因此本报告分别说明已实施方法、已完成验证和后续评价方案，不提前给出估算精度结论。

关键词：MERRA-2；M2I3NVAER；近地面 PM_{10}；区域子集；NetCDF4；时空匹配

报告内容

1 研究目标与总体技术路线

2 数据来源、产品特征与研究范围

3 数据获取、预处理与完整性控制

4 近地面 PM_{10} 估算方法

5 结果存储、空间匹配与时间统一

6 地面观测比较方案

7 当前进展、待核实事项与后续安排

参考文献；附录：复现记录与定稿清单

1 研究目标与总体技术路线

研究区域跨越不同地形和观测条件，单一地面站网难以直接提供统一、长期、完整的网格资料。本阶段拟利用 MERRA-2 的时空连续性，建立可重复计算的近地面 PM_{10} 数据集，并在后续通过地面观测检验其变化特征及偏差。扩展至周边七国的目的，是为后续区域联系和跨区域过程研究储备一致的数据基础；具体输送关系和沙尘来源仍需进一步分析。

技术路线分为五个环节：区域子集请求、原始日文件下载、组分法计算 PM_{10}、年度网格结果保存，以及目标位置匹配与观测比较。前四个环节形成可复用的数据基础，最后一个环节用于评价研究位置上的表现。

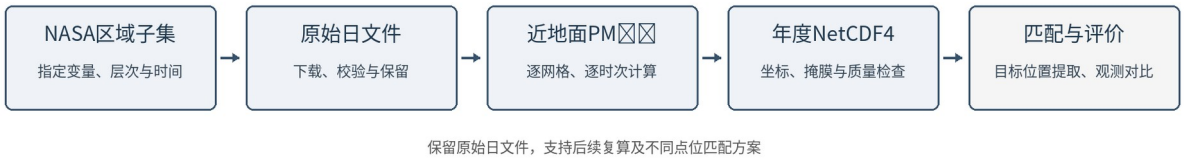


图 1 数据获取、计算与后续评价技术路线

原始网格 PM_{10} 与点位提取结果分开保存。这样在城市、站点或匹配方法调整后，可直接从现有网格结果重新提取；若需调整组分公式，也可利用保留的原始变量复算，减少重复下载。

2 数据来源、产品特征与研究范围

2.1 MERRA-2 及所选产品

MERRA-2 是 NASA 全球建模与同化办公室（GMAO）开发的再分析资料，通过数值模式和观测约束形成长期、连续的大气与气溶胶数据。本研究从 NASA GES DISC 获取 M2I3NVAER 产品。气溶胶再分析与地面 PM_{10} 直接测量的物理含义和空间代表尺度不同，需要通过独立地面资料评价[1—3]。

表 1 所用产品及关键参数

项目	本研究采用的信息
产品简称与版本	M2I3NVAER，5.12.4；文件产品标识 inst3_3d_aer_Nv
产品性质	三维、3 小时、瞬时、模式层气溶胶质量混合比产品
数据来源	NASA GES DISC；产品 DOI：10.5067/LTVB4GPCOTK2
产品时间覆盖	自 1980 年起；实际最新日期随数据发布更新
本阶段重点时期	2015 年至最新实际可用日期，未将当前年份视为完整全年

项目	本研究采用的信息
水平网格间距	经度 0.625°、纬度 0.5°；对应物理距离随纬度变化
时间坐标	每日 UTC 00、03、06、09、12、15、18、21 时
垂直层次	共 72 个模式层；选择最接近地面的第 72 层
文件格式	NetCDF4，原始日文件扩展名通常为.nc4

产品元数据明确规定 lev=1 为顶部模式层，lev=72 为底部模式层[1]。第 72 层不是固定离地高度，不能等同于地面仪器采样高度或固定的 2 米层。产品为 3 小时瞬时值，也不能直接写为 3 小时平均浓度。

2.2 区域范围与边界资料

表 2 区域划分和边界来源

范围	区域	采用资料
中国四省区	宁夏、新疆、甘肃、内蒙古	geoBoundaries CHN ADM1，固定提交版本
周边七国	蒙古国、哈萨克斯坦、吉尔吉斯斯坦、塔吉克斯坦、阿富汗、巴基斯坦、印度	Natural Earth v5.1.2，1:50m 国家级边界

国家和省级边界用于区域子集与网格筛选，具体范围以实际采用版本为准。两类资料的来源、层级及概化程度不同，应分别记录[4—5]。边界版本不能替代后续点位覆盖检查；对沿海、岛屿和边境目标，需要核实相邻有效网格是否保留。

3 数据获取、预处理与完整性控制

3.1 NASA 区域子集获取

通过 Python 调用 NASA Harmony 服务，提交研究区域多边形、起止时间、所需变量和 lev=72 条件，仅获取 PM_{10} 估算所需的数据。任务按区域、按年份组织，便于单独恢复和补齐；年代目录仅用于文件管理，不表示将十年数据合成为一个服务端任务。

服务端处理完成后，获取逐日结果链接并保存为年度 TXT 清单，同时记录任务编号、请求范围、状态及链接有效期。随后由下载程序读取清单，保存原始 NetCDF 日文件。因此，链接获取与实体数据下载是两个环节。任务完成状态和链接日期覆盖均满足要求后，才能将清单用于完整年度处理。

3.2 日文件下载和区域预处理

下载程序先完成首个缺失文件的认证，再并发下载后续文件。每次运行输入一次账号和密码，在本次国家和年份任务中复用；凭据不写入研究数据。已有文件经过校验后复用，完整年度结果通过检查后跳过。并发用于减少网络等待，实际速度受服务端负载、网络和磁盘共同影响。

本地读取时检查时间、变量、层次、单位及经纬度。计算沿用原始网格，不在本阶段人为加密或重新插值。依据区域多边形筛选网格中心，构建区域掩膜，区域外位置设置为缺失。对区域边缘目标，后续匹配前单独检查是否需要补充网格。

3.3 时间覆盖与文件质量控制

表 3 下载与计算的质量控制内容

检查对象	检查内容	处理原则
任务与链接	任务状态、编号、有效期及日文件日期	不将部分成功结果标记为完整年度
年度日文件	起止日期连续、无缺失或重复	历史完整年对应 365 或 366 个日文件
日内时间	UTC 每 3 小时一个时次、顺序一致	完整日应有 8 个时次；当前年按实际截止检查
变量与层次	14 个必要变量、第 72 层、单位和维度	缺变量、层次或单位异常时暂停计算并核查
空间网格	日文件经纬度一致、区域有效网格覆盖	不以文件能打开代替空间一致性检查
结果数值	缺失、非有限值、空气密度及异常浓度	保留缺失含义；不静默填零或裁剪异常
年度输出	时次总数、公式、单位及完整写入	检查通过后作为完成结果保存

例如，平年完整年度应有 365×8=2920 个时次，闰年应有 366×8=2928 个时次。当前年份仅处理数据实际覆盖的日期，不因文件以年份命名就视为全年完整。

3.4 中断、异常及可追溯性

任务处理进度达到 100%只表示执行结束，仍需检查最终状态和日期覆盖。NASA 服务端超时或部分处理失败时，保留任务记录和已成功文件，针对缺失部分补齐；不通过放宽完整性条件掩盖缺测。临时结果链接过期后，如本地文件完整可继续使用，缺失文件则需刷新链接。

程序保留区域边界校验和、请求配置、任务编号、原始文件校验信息和输出报告，使中断恢复与结果复查有据可依。具体接口异常和软件修复过程另作技术记录，不作为 PM_{10} 估算结果。

4 近地面 PM_{10} 估算方法

4.1 输入变量及单位

从第 72 模式层提取空气密度及气溶胶组分质量混合比，共 14 个变量。所有参与计算的变量必须对应相同时间和空间位置，并核对单位、维度及缺失值定义。

表 4 PM_{10} 计算的输入变量

变量名称	物理含义	单位
AIRDENS	空气密度	kg m^{-3}
SO4	硫酸盐气溶胶质量混合比	kg kg^{-1}
BCPHOBIC、BCPHILIC	疏水性、亲水性黑碳质量混合比	kg kg^{-1}
OCPHOBIC、OCPHILIC	疏水性、亲水性有机碳质量混合比	kg kg^{-1}
DU001—DU004	第 1 至第 4 粒径档沙尘质量混合比	kg kg^{-1}
SS001—SS004	第 1 至第 4 粒径档海盐质量混合比	kg kg^{-1}

4.2 组分估算公式

依据现有参考材料采用的组分方法，将相关气溶胶质量混合比加权求和，再乘以空气密度，得到近地面 PM_{10} 质量浓度。以 S 表示加权质量混合比，公式分行列示如下：

$$S = 1.375 \times SO4 + BCPHOBIC + BCPHILIC$$
$$+ OCPHOBIC + OCPHILIC + DU001 + DU002 + DU003$$
$$+ 0.74 \times DU004 + SS001 + SS002 + SS003 + SS004$$
$$PM_{10} = S \times AIRDENS \times 10^{9} \qquad (1)$$

各质量混合比单位为 kg kg^{-1}，S 与 AIRDENS 相乘后单位为 kg m^{-3}，再乘以 10^9 转换为 μg m^{-3}。当前方案中硫酸盐系数为 1.375，DU004 系数为 0.74，其余列出的组分系数为 1。代码按同一公式实现，不额外加入未明确采用的组分或系数。

公式目前依据所提供学位论文第 10 页实施。其完整书目信息、系数原始出处及适用性仍待核实，正式定稿前补齐。因此本文称其为“当前采用的文献组分方案”，不将其表述为 NASA 直接提供的 PM_{10} 变量或官方统一计算公式。

4.3 缺失值与异常处理

必要输入缺失时，相应网格和时次的结果保留为缺失，不把缺失组分视为零。区域外掩膜、区域内缺测及异常数值分别记录。对非正空气密度等不符合物理意义的输入暂停计算并核查，不在后台静默替换；对负 PM_{10} 等结果核查原因，不直接裁剪为零。

式（1）同时包含沙尘、海盐和其他气溶胶组分，所得为总 PM_{10} 估算浓度。若后续分析沙尘贡献，需要另行提取和定义沙尘组分指标；若识别沙尘事件，还需结合观测和事件判据。总 PM_{10} 高值本身不能直接证明发生沙尘过程。

5 结果存储、空间匹配与时间统一

5.1 逐时次计算和年度保存

计算按日文件、按时次顺序读取所需变量，完成单个时次后写入年度文件，避免将全部年份和组分一次载入内存。中间计算采用 float64，最终 PM_{10} 以 float32 存储并使用 NetCDF4 压缩。压缩对已存储数据是无损的，但 float64 转 float32 存在舍入，两者应区分。

原始日文件与年度网格 PM_{10} 同时保留。NetCDF4 能够组织时间、纬度和经度维度，并保存单位、缺失值、掩膜和公式说明；相较于全网格 CSV 展开，更适合多年网格资料的管理及按需读取。后续仅对目标点提取结果输出 CSV 或 Parquet，减少表格规模。

表 5 数据分层保存及用途

数据层次	保存方式	主要用途
任务和链接	按地区／年代／年份保存 JSON 和 TXT	任务恢复、日期检查及下载入口
原始变量	按地区／年份保存逐日.nc4	核查组分、调整公式和复算
网格 PM_{10}	按地区、每年一个 NetCDF4	保留完整区域网格和原始 3 小时时次
目标位置序列	按国家或省份／城市或站点组织	观测配对、统计分析和成果输出

5.2 最近邻空间匹配

后续依据目标点经纬度，以球面距离选择最近的原始网格中心，并提取相应时间序列。结果保留输入坐标、匹配网格坐标及距离。该方法已进行流程测试，最终应用仍需检查点位来源和区域覆盖。多个点位可能匹配同一网格，反映数据分辨率限制。

现有 city 四省.xlsx 包含 45 个城市或地级行政区代表点，其中内蒙古 12 个、甘肃 14 个、宁夏 5 个、新疆 14 个。现有字段不足以认定为空气质量监测站，本文暂称“给定代表点”。正式站点比较需核实名称、编号、坐标来源及参考系统，不能由此前气温匹配用途推定其为空气质量站。

边界附近的最近网格可能位于区域掩膜之外，应检查必要网格是否被保留，必要时补充局部数据。不得以距离更远的区域内网格自动替代，而不记录这一改变。

5.3 时间统一和输出字段

网格结果保留 UTC 时间。国内展示可增加北京时间 UTC+8；年末 UTC 时次转换后落入次年属于正常时区转换。跨国日均统计需要明确采用 UTC 日还是所在地日，不能统一套用北京时间日界。

产品瞬时值、观测小时均值和观测日均值的时间含义不同，应根据观测时间戳制定配对窗口及有效比例要求。由每日 8 个瞬时值形成的均值应明确为“8 时次均值”，不未经评估就等同于 24 小时观测日均值。

建议输出字段为国家／省份、城市／站点及编号、目标经纬度、匹配网格经纬度、距离、UTC 时间、必要的当地时间、PM_{10} 和质量标识。城市多年序列如超过表格软件显示限制，可按年拆分或采用 Parquet；软件行数限制不等于数据无法存储。

6 地面观测比较方案

6.1 比较对象与数据准备

若观测为单站资料，使用该站坐标提取；若为城市平均浓度，需记录参与站点及平均方法。城市代表点对应网格与城市平均值的比较可以作为探索性分析，但需说明空间代表性差异。国外资料同样应核查污染物类型，避免将气象站或仅提供 $PM_{2.5}$ 的站点作为 PM_{10} 观测源。

配对前统一浓度单位和时间基准，核查观测质量标识、缺测、站点迁移及温压换算定义。缺失值不填零；本阶段不预设对 PM_{10} 缺测进行线性插值，以免改变污染高值过程。只有满足统一质量规则的配对进入评价，并报告各位置的有效样本数及覆盖时段。

6.2 指标与图表

令 M_i 为第 i 组配对中的 MERRA-2 估算值，O_i 为观测值，N 为有效配对数。拟采用平均偏差（MB）、平均绝对误差（MAE）、均方根误差（RMSE）和相关系数 r，从系统偏差、误差幅度及变化一致性评价。

$$MB = (1/N)\ \Sigma_{i=1}^{N}\ (M_i - O_i) \qquad (2)$$

$$MAE = (1/N)\ \Sigma_{i=1}^{N}\ |M_i - O_i| \qquad (3)$$

$$RMSE = \sqrt{[(1/N)\ \Sigma_{i=1}^{N}\ (M_i - O_i)^2]} \qquad (4)$$

MB 为正表示整体偏高，负值表示整体偏低；MAE 和 RMSE 均以 $\mu g\ m^{-3}$ 表示，后者对大误差更敏感。相关系数用于评价变化一致性，不代替浓度偏差评价。样本过少或某一序列无变化时不强行计算 r。

表 6 拟形成的比较成果

成果	主要内容	对应问题
时间序列图	同位置、同尺度的估算与观测变化	季节变化和污染过程是否一致
散点图	估算值与观测值、1:1 参考线	有无整体偏差及高值偏离
指标汇总表	N、有效时段、MB、MAE、RMSE、r	不同位置的误差和样本覆盖差异
分组分析	季节或明确判据下的高浓度过程	方法适用条件与过程差异

6.3 结果解释原则

差异可能涉及网格尺度、复杂地形、局地排放、近地面层高度、时间抽样和组分参数化等。分析应结合具体证据，避免把所有差异归于单一原因。目前尚无完整、经核查的地面 PM_{10} 配对结果，本节为评价方案，不能提前写入“准确性较高”等结果性结论。

7 当前进展、待核实事项与后续安排

7.1 当前完成情况

已完成产品与变量选择，建立区域子集链接获取、日文件下载及逐时次 PM_{10} 计算流程，并开展完整年度和给定坐标提取测试。多区域、多年份任务正在推进，完成范围需以年度文件和运行记录逐项统计。

表 7 现阶段工作及证据边界

工作环节	当前进展	尚需完成
数据选择	产品、层次和 14 变量已确定；产品标识与 DOI 核对	补齐方法原始文献及变量适用性核查
年度处理流程	蒙古国 2024 年 366 日、2928 时次处理完成	逐区域逐年盘点并检查区域内缺失和异常
多年数据获取	自动化获取和恢复流程已建立，任务持续推进	补齐失败任务及未完成年份
位置提取	给定坐标的匹配流程已开展测试	确认代表点或站点身份、坐标和覆盖
观测比较	评价框架与指标已提出	获取并核查地面资料，实际配对及计算指标

蒙古国 2024 年的运行结果为 366 个日文件、2928 个时次，年度文件约 6.30 MiB。该数值仅为当前区域和配置下的实际示例，不用于推定其他国家体积或下载耗时。它证明整年流程完成，不证明浓度估算已经通过地面观测验证。

7.2 关键待核实事项

第一，补齐 PM_{10} 公式文献书目信息和系数原始出处。第二，核实 45 个给定代表点的来源、坐标格式和参考系统。第三，明确国内外观测数据的污染物、站点／城市定义、有效年份及时间统计尺度。第四，盘点实际完成的数据范围，区分完整历史年、当前年阶段结果与尚缺年份。

7.3 后续工作安排

（1）形成“地区—年份—链接—原始日文件—年度 PM_{10}”的完成情况台账，补齐缺失数据。

（2）抽查原始组分与 PM_{10} 计算结果，检查时间连续性、区域覆盖及异常值。

（3）确认点位与观测资料后，选择资料较完整的地区和年份完成首轮配对。

（4）形成时间序列、散点图和评价指标表，再分析季节和高浓度过程差异。

（5）在上述方法确认后扩展到更多年份和位置，并按城市或站点组织多年序列。

本阶段的主要成果是形成可追溯、可复用的数据获取与 PM_{10} 估算流程。下一阶段重点从“流程完成”转向“观测评价”，通过实际配对数据判断估算结果的适用范围与局限。

参考文献与资料来源

[1] Global Modeling and Assimilation Office (GMAO). MERRA-2 inst3_3d_aer_Nv: 3d, 3-Hourly, Instantaneous, Model-Level, Assimilation, Aerosol Mixing Ratio V5.12.4 (M2I3NVAER)[DS]. Greenbelt, MD: NASA Goddard Earth Sciences Data and Information Services Center, 2015. DOI: 10.5067/LTVB4GPCOTK2.

[2] Gelaro R, McCarty W, Suárez M J, et al. The Modern-Era Retrospective Analysis for Research and Applications, Version 2 (MERRA-2)[J]. Journal of Climate, 2017, 30(14): 5419–5454. DOI: 10.1175/JCLI-D-16-0758.1.

[3] Randles C A, da Silva A M, Buchard V, et al. The MERRA-2 Aerosol Reanalysis, 1980 Onward. Part I: System Description and Data Assimilation Evaluation[J]. Journal of Climate, 2017, 30(17): 6823–6850. DOI: 10.1175/JCLI-D-16-0609.1.

[4] Natural Earth. Admin 0 – Countries, 1:50m, v5.1.2[DS/OL]. 实际采用文件：https://raw.githubusercontent.com/nvkelso/natural-earth-vector/v5.1.2/geojson/ne_50m_admin_0_countries.geojson.

[5] geoBoundaries. CHN ADM1, gbOpen[DS/OL]. 采用提交 5c25134028196d43ce97b5071934fd0cfc92f09f 下的 releaseData/gbOpen/CHN/ADM1/geoBoundaries-CHN-ADM1.geojson。

公式来源待补：现有材料为北京大学硕士学位论文第 10 页。作者、题名、年份及其所引系数原始资料尚待确认，未将其编造为完整参考文献。

附录 A 复现所需记录

A1. 产品：M2I3NVAER 5.12.4；CMR 集合 C1276812882-GES_DISC。产品名、时间性质、层次和 DOI 已于 2026-10-21 通过 NASA CMR 元数据核对。

A2. 国界：Natural Earth v5.1.2；源文件 SHA-256 为 3e458fc036ad0a66411f2c1e6cac49c5d7bfb81cb1123bc513b22511a2b7fdeb。

A3. 国内省界：geoBoundaries 固定提交同参考文献[5]；源文件 SHA-256 为 3a00467a0db9b4136facb5f2f3d0edbfd96adb15651cfdf63991da9281030e85。

A4. 计算：保存请求时间、14 变量、lev=72、公式、程序版本、原始文件校验信息、时间／空间／数值检查报告及年度输出元数据。

A5. 匹配：保存目标坐标、坐标来源与参考系统、网格坐标、距离、时间换算规则、观测来源及质量筛选规则。账号密码和授权令牌不写入研究结果。